

Construction and Benchmark Analysis of a High-Quality Korean Smishing Dataset for Smishing Detection

Kim Jin Myeong^{*}, Lee Si Eun[†], Kim Do Gook[†]

스미싱 탐지를 위한 고품질 한국어 스미싱 데이터셋 구축 및 벤치마크 분석

김진명^{*}, 이시은[†], 김도국[†]

ABSTRACT

This study addresses the limitations of prior smishing detection research, which has primarily focused on binary classification, by constructing a large-scale Korean smishing corpus named the KorSmishing dataset. Unlike conventional datasets that provide only ground-truth labels, KorSmishing incorporates explanation data that logically describes the threat components of each message. This explanatory layer constitutes a key differentiator of the dataset.

In particular, the explanation data were generated based on domain-specific knowledge, including formal definitions of smishing, representative attack cases, and established prevention strategies. To validate the practical utility of the constructed dataset, we conducted benchmark experiments using models of varying scales, including CNN, Kc-ELECTRA, and EXAONE.

Experimental results demonstrate that the proposed dataset achieves strong detection performance even with small-scale large language models (sLLMs) that have relatively few parameters. These findings indicate that K-Smishing is a high-quality research resource capable of advancing a broad spectrum of detection methodologies, ranging from traditional statistical approaches to state-of-the-art lightweight LLMs optimized for real-world mobile environments.

Keywords : Smishing Detection, Korean Corpus, Explanation Data, Lightweight LLM

요약

본 연구는 기존 이진 분류 중심의 스미싱 탐지 연구 한계를 극복하기 위해, 대규모 한국어 스미싱 말뭉치인 K-Smishing 데이터셋을 구축하였다. 본 데이터셋은 단순한 정답 라벨링을 넘어 각 메시지의 위협 요소를 기술한 설명 데이터(Explanation Data)를 포함하고 있다는 점이 기존 데이터셋과의 핵심적인 차별점이다. 특히, 설명 데이터는 스미싱의 정의, 사례, 예방법 등 전문적인 도메인 지식을 바탕으로 생성되었다. 구축된 데이터셋의 활용 가능성을 검증하기 위해 CNN, KcELECTRA, EXAONE 등 다양한 규모의 모델을 활용하여 벤치마크 실험을 수행하였다. 그 결과, 본 데이터셋은 파라미터 수가 적은 경량화된 LLM(sLLM)에서도 탁월한 탐지 성능을 기록하였다. 이는 본 데이터셋이 전통적인 통계적 기법부터 경량 LLM에 이르기까지, 폭넓은 탐지 알고리즘 고도화에 기

여할 수 있음을 시사한다.

키워드 : 스미싱 탐지, 한국어 말뭉치, 설명 데이터, 경량 LLM

1. 서론

최근 과학기술정보통신부와 한국인터넷진흥원(KISA)이 발표한 사이버 위협 동향 보고서에 따르면, 국내 사이버 침해사고 신고 건수는 2024년 1,887건에서 2025년 2,383건으로 약 26.3% 증가한 것으로 나타났다. 또한 유출된 개인정보가 보이스피싱이나 스미싱과 같은 2차 범죄에 악용될 가능성이 높아지면서 이에 대한 대응 필요성이 더욱 강조되고 있다 [1].

이처럼 모바일 메시지는 현대인의 필수적인 소통 수단이 되었으나, 이러한 편리함은 '스미싱(Smishing)'이라 불리는 금융 범죄의 통로가 되기도 한다. 최근 스미싱 공격은 공공 기관이나 지인을 사칭하여 사용자의 심리적 긴박감을 유도하며, 결과적으로 막대한 재산적·정신적 피해를 야기하고 있다. 그러나 현재 존재하는 한국어 스미싱을 위한 데이터셋은 몇 가지 중요한 문제에 직면해 있다. 첫째, 대부분의 공개 데이터셋은 단순 이진 분류 라벨링에 국한되어 있어, 판단 근거를 학습하거나 제시해야 하는 '설명 가능한 AI(XAI)' 연구[2]를 수행하기에는 데이터의 정보량이 부족하다. 둘째, 최신 스미싱 사례들을 폭넓게 포괄하며 모델의 일반화 성능을 객관적으로 검증할 수 있는 대규모 한국어 말뭉치가 희소한 실정이다.

이러한 문제를 해결하기 위해, 본 연구에서는 K-Smishing이라는 새로운 대규모 한국어 스미싱 데이터셋을 제시하며 다음과 같은 세 가지 핵심적인 기여를 목표로 한다.

1) 실사례 중심의 고품질 데이터셋 구축: 한국인터넷진흥원(KISA), 실제 사용자 제보 및 구글 검색 등을 통해 수집

된 총 18,270개의 메시지로 구성된 대규모 한국어 말뭉치를 구축하였다.

2) 도메인 지식 기반 설명 데이터(Explanation Data) 제공: 단순 라벨링에 그치지 않고, 스미싱의 정의와 유형별 사례 등 전문 지식을 반영하여 각 메시지의 위험 근거에 대한 설명 데이터를 생성하였다. 이를 통해 모델이 단순 예측을 넘어 논리적 근거를 제시할 수 있도록 한다.

3) 벤치마크를 통한 효용성 및 범용성 검증: 구축된 데이터셋의 실효성을 입증하기 위해 다양한 아키텍처를 활용한 벤치마킹을 수행하였다. 실험 결과, 아키텍처에 관계없이 일관되게 높은 성능을 보이며 다양한 모델에서 활용 가능한 데이터셋임을 확인하였다.

2. 데이터셋 구축

2.1 데이터 수집

스미싱 메시지는 실제 공격 사례를 확보하는 것이 무엇보다 중요하므로, 한국인터넷진흥원의 데이터 활용 승인을 받기 위해 정식 회원가입 및 연구 목적 승인 절차를 수행하였으며, 이를 통해 확보한 최신 5개년 스미싱 데이터를 바탕으로 실제 침해 사고로 분류된 고유한 메시지 사례들을 수집하였다. 이에 더해 공공데이터와 개인 메시지를 병행함으로써, 최근 기승을 부리는 자녀 사칭이나 정부 지원금 사칭 등 최신 스미싱 유형까지 폭넓게 포괄하여 데이터의 완성도를 높였다.

스미싱 탐지의 핵심인 FP(False Positive)를 낮추기 위해서는 양질의 정상 데이터가 필수적이다. 이를 위해 실제 개인용 모바일 기기의 메시지 내역을 바탕으로 실생활 기반의 원천 데이터를 수집하였다. 이는 실제 사용자가 일상에서 접하는 메시지의 맥락을 가장 정확하게 반영하기 위함이다. 이 과정에서 스미싱과 정상의 경계에 있는 스팸성 광고와 마케팅 메시지를 엄격히 분리하는 과정도 거쳤다.

2.2 데이터 유형

스미싱 공격은 단순히 특정 키워드나 문장을 기반으로 이루어지는 것이 아니라, 공격자가 사용자의 심리를 유도하기 위해 다양한 전략을 활용하고 메시지 형태를 지속적으로 변화시키는 특징을 가진다. 따라서 AI 모델이 이러한 공격 패턴을 효과적으로 학습하기 위해서는 특정 유형에 편중된 데이터가 아니라 실제 환경에서 나타나는 다양한 메시지 유형과 변형 패턴을 포함한 데이터셋이 필요하다. 특히, 동일한 문장 구조를 유지하면서도 링크(URL), 전화번호, 금액 등의 일부 요소만 변경하여 유포되는 스미싱 메시지의 특성을 반영함으로써, 메시지의 구조적 특징과 의미적 패턴을 학습할 수 있도록 하는 것이 중요하다.

따라서 본 데이터셋 구축 과정에서는 이러한 실제 공격 패턴을 반영하기 위해 동일한 메시지 구조를 유지하면서 링

크(URL), 전화번호, 금액 등 일부 요소만 변경된 메시지들도 데이터셋에 포함하였다. 예를 들어 “[국외발신][텔레그램]108712**** SM-S791 기기등록본인이 아니라면 확인요망.org.”과 “[국제발신][텔레그램]108717** SM-S791 기기등록본인이 아니라면 확인요망.**.tel”과 같이 동일한 문장 구조를 유지하면서도 번호와 주소가 서로 다른 형태의 메시지가 존재한다. 이를 통해 구축한 데이터셋으로 학습된 AI 모델은 단순한 키워드나 특정 URL에 의존하는 것이 아니라, 공격자가 사용하는 전략과 메시지의 구조적 특징을 학습하도록 하였다.

또한 실제 문자 환경에서는 개인 간 대화나 일상적인 정보 전달 메시지가 많은 부분을 차지한다. 따라서 인터넷에서 수집한 다양한 일상 대화 패턴도 데이터셋에 포함하였다. 예를 들어 “김은숙 작가 때문에 도깨비를 봤는데 정말 공유가 멧내지 않으면서도 슬픔과 기쁨을 잘 표현하더라.”, “연아 화이팅 대한민국 만세!!!”와 같이 특정 공격 의도나 링크가 포함되지 않은 자연스러운 일상 대화 메시지들을 함께 수집하였다. 이러한 정상 대화 데이터는 스미싱 메시지와 의 언어적·맥락적 차이를 학습하도록 하여 모델이 보다 현실적인 문자 환경에서 동작할 수 있도록 의도하였다.

결과적으로 K-Smishing 데이터셋은 지인 사칭, 금융·계정 보안 알람, 공공기관 사칭, 배송 안내, 이벤트 및 설문 참여 유도, 구인구직 안내, 광고성 메시지 등 실제 환경에서 관찰되는 다양한 스미싱 공격 시나리오뿐 아니라, 일반적인 일상 대화 메시지도 포함하도록 구성하였다. 이러한 데이터 설계로 변화하는 스미싱 공격 패턴에 대해 보다 일반화된 벤치마크를 확보하였다.(Fig. 1)




Fig. 1. Data Type

2.3 Explanation Data 생성

스미싱 탐지 모델의 결과에 대한 신뢰성을 확보하고, 향후 사용자에게 판단 근거를 제공할 수 있게 수집된 각 메시지에 대한 Explanation Data를 생성하였다. 방대한 양의 데이터에 대해 일관성 있고 고품질의 설명을 확보하기 위해 GPT-4o로 생성하였다.

단순히 모델에게 설명을 요청하는 대신, (Fig. 2)과 같이 정교하게 설계된 시스템 프롬프트를 주입하여 모델이 금융

보안 전문가의 페르소나를 수행하도록 유도하였다. 시스템 프롬프트에는 스미싱의 명확한 정의와 함께 기관 사칭, 자녀 사칭(예: 휴대전화 고장 알림), 미납 벌금 안내 등 구체적인 최신 공격 사례와 피해 예방 수칙 등의 Domain Knowledge가 포함되었다.




Fig. 2. Explanation Data Generation Algorithm

3. 데이터셋 분석

수집된 데이터셋을 8가지 주요 카테고리로 분류하고, 정상 메시지와 스미싱 메시지의 언어적·구조적 특징을 대조 분석하였다. 카테고리별 세부 분석 결과는 <Table. 1>과 같다.

Table 1. Dataset results

	정상 메시지	스미싱 메시지	핵심 키워드	공격 패턴
결제	[NH채움]이*은님, 08/02 20:23 USD 49.99 Google Colab/본인 미사용시 연락요망	[Web발신] (6*0*)결 제 2018/12/10 09:50 EAIBUY 사용 99,300원 (부가세포함) 문의 07076*****	주문 완료	주문확인을 위한 url 접근을 유도하는 패턴
공공기관	[**시경찰청] 경찰은 **시에서 실종된 ***씨(남, 59세)를 찾습니다 - 179cm... vo.la/QDC9tG	[경찰청교통 (이파인)] 교통법위반 벌점통지서 (발송)내용 http://ino.**cd3p.one	벌점, 위반	긴급 상황 및 심리적 위축을 유도하는 패턴
구글폼	[Web발신] [***-SW중심대학사업단] 제22회 TOPCIT 정기평가 접수	[Web발신]8월 여름EVENT 동행복권 설문조사참여후 경품받기-홍보	경품 이벤트	단순 참여를 유도해서 고가의 보상을 제시하는 패턴

	https://forms.gle/kBihz4MA1g517wPT6	대사배우 ***- https://vvd.bz/fiMA		
택배	[한진택배] 부재중이신 고객님의 위해 위탁장소에 2025-11-11 20:31:42에 배송하였습니다. 감사합니다.	[대한통운] 고객 당신의 물품 배송 실패 주"소 오류 즉시 주소변경: https://bully.kr/ ****	배송 실패	택배물 손실, 주소 오류 등의 이유로 스미싱 클릭 유도를 유도하는 패턴
구인구직	★2023 평택시 중장년 일자리 박람회 개최 안내○일 시:2023.6.29.(목) 14:00~17:00...	(주)코어컴퍼니 사무보조 배송직 남녀 (신입,경력) 00모집 팀장 2모집 카톡:****	모집	구체적 직무 설명이 결여되고 모호한 패턴
광고	[Web발신] (광고)**피자 10월 KT 달달해택! 온라인 방문포장 50% 무료거부**03082	안녕하세요. ★인투88가입... 라이선스 보유해외사이트 *모든이벤트 롤링 100% ▶ https://**8.w.in...	가입	통상적 범위를 벗어난 과도한 현금성 혜택 노출하는 패턴
기타	-	[Web발신] 드디어 저희 결혼합니다 오셔서 격려 해주세요 위치 : 노블레스 웨딩 https://***.in/0r0	사칭	가족, 지인 간의 정서적 유대감 및 신뢰를 악용하는 패턴

스미싱 메시지는 단순히 악성 링크를 포함하는 수준을 넘어 사용자의 행동을 유도하기 위한 다양한 전략을 활용한다. 특히, 대부분의 공격 메시지는 사용자의 긴급성 인식, 경제적 이익 기대 또는 개인적 신뢰 관계와 같은 심리적 요인을 자극하는 방식으로 설계되어 있다.

또한, 공식 기관 또는 공신력 있는 조직을 사칭하는 패턴도 빈번하게 관찰되었다. 이 유형의 메시지는 정부기관, 금융기관, 공공 서비스 등을 언급하며 벌금, 계정 제한, 보안 문제와 같은 상황을 제시하여 사용자의 심리적 압박을 유도한다. 특히 긴급성을 강조하는 표현을 함께 사용하여 사용자가 메시지의 진위를 충분히 검토하기 전에 즉각적인 행동을 취하도록 유도하는 경향이 나타났다.

일부 메시지는 경제적 보상이나 혜택을 강조하는 방식으로 사용자의 참여를 유도하는 특징을 보였다. 이벤트 참여, 설문 응답, 간단한 정보 입력 등을 요구하면서 고가의 상품이나 금전적 보상을 제시하는 방식이 대표적이다. 이러한 유형은 상대적으로 위협적인 표현 대신 긍정적인 보상 메시지를 활용하여 사용자의 경계심을 낮추는 특징이 있다.

취업 정보나 아르바이트 제안을 가장하는 메시지도 관찰되었다. 이 유형은 높은 수익이나 간단한 업무 조건을 강조하고 있지만 실제 업무 내용이나 기업 정보는 명확하게 제시하지 않는 경우가 많다. 이러한 모호한 정보 구조는 사용자의 추가 연락이나 외부 링크 접근을 유도하기 위한 전략으로 해석된다.

마지막으로 가족이나 지인과의 관계를 악용하는 형태도 나타났다. 이러한 메시지는 친밀한 관계에서 발생할 수 있는 상황을 제시하며 도움 요청이나 긴급 연락을 요구하는 방식으로 구성된다. 이는 사용자의 정서적 반응을 유도하여 메시지의 진위 여부를 충분히 판단하기 전에 행동하도록 만드는 전형적인 사회공학작 공격 방식이다.

이와 같이 본 데이터셋에 포함된 스미싱 메시지는 다양한 전략을 기반으로 구성되어 있다. 이러한 특성이 스미싱 탐지 모델에 반영되어 단순 키워드 기반 탐지를 넘어 메시지의 맥락적 특징과 공격 전략을 대비할 수 있음을 시사한다.

4. 벤치마크 실험

구축된 K-Smishing 데이터셋의 효용성을 검증하고, 최신 언어 모델이 스미싱 탐지 및 설명 생성에 기여하는 바를 측정하기 위해 아키텍처별 벤치마킹을 수행하였다.

4.1 대상 모델 및 학습 전략

1) NLP_CNN: 메시지의 지역적 특징과 단어 빈도를 기반 [3]으로 스미싱 여부만을 측정하는 방법으로 학습하였다.(Fig. 3)




Fig. 3. CNN_NLP architecture

2) FastText: 단어의 Subword Information를 반영하는

n-gram 기반의 임베딩 모델[4]로, 딥러닝 아키텍처가 아닌 통계적 효율성을 검증하기 위한 대조군으로 활용하였다.

3) KcELECTRA[5]: 한국어 구어체와 신조어에 특화된 Pre-trained Language Model으로, 메시지 본문과 라벨 간의 문맥적 상관관계를 학습하였다.

4) EXAONE[6](Explanation-aware Training): 메시지 본문 및 라벨과 더불어 GPT-4o로 생성된 설명 데이터를 함께 입력하여 Fine-tuning을 진행하였다.

5. 벤치마크 실험 결과 및 분석

머신러닝 기반 모델, 딥러닝 기반 모델, 사전학습 언어모델 및 생성형 LLM을 포함하여 다양한 접근 방식에서의 탐지 성능을 비교하는 방식으로 진행하였다<Table. 2>.

Table 2. Performance across Metrics

	Model	Accuracy	Macro F1	F1 (Smishing)	F1 (Normal)	Precision (Smishing)	Recall (Smishing)
DL	CNN	0.9908	0.9900	0.9900	0.9900	0.9900	1.0000
ML	FastText	0.9378	0.9368	0.9447	0.9288	0.9830	0.9093
LLM	Kc-ELECTRA	0.9289	0.9247	0.9426	0.9068	0.8938	0.9970
Generative LLM	Exaone	0.9261	0.9217	0.9402	0.9033	0.8925	0.9933
	Gemini	0.8950	0.8944	0.9023	0.8864	0.9892	0.8295
	Chat GPT	0.7079	0.6786	0.7757	0.5816	0.7041	0.8634

먼저 딥러닝 기반 모델로 CNN(Convolutional Neural Network)[2]에 적용한 결과, Accuracy는 약 0.99 수준으로 나타났으며 Macro F1-score, Precision, Recall 역시 모두 0.99 수준의 높은 성능을 기록하였다. 이는 스미싱 메시지가 특정 키워드뿐 아니라 문장 구조나 패턴과 같은 지역적 텍스트 특징을 포함하고 있기 때문에 이러한 특징을 효과적으로 학습할 수 있는 CNN 구조가 높은 분류 성능을 보인 것으로 해석된다.

머신러닝 기반 접근으로는 FastText[3] 모델을 활용하였다. 실험 결과 성능은 0.90~0.98 수준으로 나타났으며, 이는 딥러닝 모델에 비해 다소 낮지만 여전히 높은 탐지 성능을 보였다. FastText는 단어 단위뿐 아니라 subword 정보를 활용하는 특성을 가지기 때문에 스미싱 메시지에서 자주 나타나는 URL, 숫자, 변형된 단어 구조 등을 일정 수준 효과적으로 처리할 수 있었던 것으로 판단된다.

사전학습 언어모델 기반 접근에서는 KcELECTRA[4]를 활용하여 실험을 수행하였다. 그 결과 성능은 약 0.92~0.99 수준으로 나타났다. 이는 대규모 한국어 말뭉치로 사전학습된 언어모델이 문장의 의미적 맥락을 효과적으로 이해하여 스미싱 메시지와 정상 메시지를 구분할 수 있음을 보여준

다. 특히 기존 키워드 중심 탐지 방식과 달리 문맥적 특징을 활용한 분류가 가능하다는 점에서 의미가 있다.

또한 생성형 LLM 모델인 EXAONE[5]을 본 데이터셋으로 파인튜닝하여 실험을 수행한 결과 성능은 약 0.92 수준으로 나타났다. Zero-shot방식의 Generative LLM(ChatGPT, Gemini-pro)을 별도의 학습 없이 수행한 분류 결과 약 0.70~0.89 수준으로 나타났다. 이는 본 데이터셋의 혼련으로 스미싱 탐지율을 높일 수 있음을 시사한다.(Fig. 4)




Fig. 4. Benchmark Model Prediction Results

(Fig. 5)는 정상 메시지와 스미싱 메시지를 입력했을 때 모델의 예측 결과와 함께 Explanation Data가 어떻게 제공되는지를 보여주는 예시이다. 먼저 정상 메시지의 경우 모델은 해당 메시지를 정상으로 분류하였으며, 설명 데이터에서도 특정 공격 패턴이나 악성 의도가 발견되지 않는다는 근거가 제시된다. 즉, 메시지의 내용이 단순한 정보 전달 또는 일반적인 안내 메시지의 형태를 가지며 스미싱에서 흔히 나타나는 링크 유도, 개인정보 입력 요구, 기관 사칭 등의 특징이 존재하지 않음을 설명을 통해 확인할 수 있다.

반면 스미싱 메시지의 경우 모델은 해당 메시지를 스미싱으로 분류하였으며, Explanation Data에서는 메시지 내에 포함된 위험 요소를 구체적으로 설명한다. 예를 들어 특정 기관을 사칭하는 표현, 긴급 상황을 유도하는 문구, 외부 링크 클릭을 요구하는 구조 등이 스미싱 공격의 대표적인 특징으로 제시된다. 이러한 설명은 단순히 분류 결과만 제공하는 것이 아니라, 해당 메시지가 왜 위험한지에 대한 근거를 사용자에게 제공한다는 점에서 의미가 있다.




Fig. 5. Benchmark Model Prediction Results

6. 결론 및 향후 연구

결론적으로 본 데이터셋은 전통적인 머신러닝 모델부터 딥러닝 및 대규모 언어모델에 이르기까지 다양한 아키텍처에서 안정적인 탐지 성능을 확보할 수 있음을 확인하였다. 다양한 모델을 벤치마킹하며 고품질임을 입증한 본 데이터셋을 오픈소스화하여 한국인 스미싱 피해 예방에 실질적으로 기여하고자 한다. 더 나아가 보이스피싱과 같은 텍스트가 아닌 분야에서도 적용 가능한 데이터셋을 구축하여 고품질 보안 생태계를 위해 후속 연구를 지속할 계획이다.

References

- [1] 과학기술정보통신부, “2025년 사이버 위협 동향과 2026년 사이버 위협 전망 보고서,” 보도자료, 2025
- [2] Barredo Arrieta, Alejandro; Diaz-Rodriguez, Natalia; Del Ser, Javier; Bennetot, Adrien; Tabik, Siham; Barbado, Alberto; Garcia Lopez, Salvador; Gil-Lopez, Sergio; Molina, Daniel; Benjamins, Richard; Chatila, Raja; Herrera, Francisco, Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI, Information Fusion, 58, – 82–115, 2019.
- [3] Kim, Yoon, Convolutional Neural Networks for Sentence Classification, Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar, 2014, 1746–1751.
- [4] Bojanowski, Piotr; Grave, Edouard; Joulin, Armand; Mikolov, Tomas, Enriching Word Vectors with Subword Information, Transactions of the Association for Computational Linguistics, 5, – 135–146, 2017
- [5] Clark, Kevin; Luong, Minh-Thang; Le, Quoc V.; Manning, Christopher D., ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators, Proceedings of the International Conference on Learning Representations (ICLR), Addis Ababa, Ethiopia, 2020, 1–18.
- [6] Bae, Kyunghoon; Choi, Eunbi; Choi, Kibong et al. EXAONE 4.0: Unified Large Language Models Integrating Non-reasoning and Reasoning Modes, arXiv preprint arXiv:2507.11407, 2025.